

# ASAP - Análise Sentimental de Artigos Políticos

Jérôme de Figueiredo  
Instituto Superior Técnico -  
Tagus Park  
Av. Prof. Doutor Aníbal  
Cavaco Silva  
Porto Salvo, Portugal  
jerome.figueiredo@ist.utl.pt

Nádia Gonçalves  
Instituto Superior Técnico -  
Tagus Park  
Av. Prof. Doutor Aníbal  
Cavaco Silva  
Porto Salvo, Portugal  
nadia.goncalves@ist.utl.pt

## ABSTRACT

### 1. INTRODUÇÃO

Este projecto foi desenvolvido no âmbito da UC (Unidade Curricular) de Extração e Análise de Dados Web, com o intuito de extrair e analisar documentos da natureza política. O desenvolvimento deste projecto teve também como finalidade, a aplicação de conceitos e tecnologias abordadas na UC durante as aulas teóricas e práticas.

### 2. EXTRAÇÃO DE FEEDS

Nesta secção, será abordada a forma como as notícias e respectivas necessárias informações são extraídas e armazenadas de forma se efectuar a análise das mesmas. Também será abordado o mecanismo de detecção de notícias duplicadas.

#### 2.1 Método de Extração

No início da execução deste projecto é pedido ao utilizador para se inserir o endereço de feed pretendido para análise (ex.: <http://feeds.dn.pt/DN-política>). Note-se que é necessário inserir o link completo como descrito no exemplo.

Um vez o feed inserido, para a extração dos títulos das notícias é usado a ferramenta feedparser com a função *post.title*. Esta função faz parte da ferramenta feedparser e retira directamente os títulos dos artigos. A extração do conteúdo dos artigos é feita com a ferramenta BeautifulSoup. Esta ferramenta inclui as necessárias funções para analisar páginas HTML e extrair a informação pedida segundo uma série de critérios. Neste projecto, a ferramenta procura nas tags HTML o o critério *id = Article* e extrai o seu conteúdo.

#### 2.2 Indexação

A indexação da notícia é feita com a auxílio da ferramenta Whoosh. Esta função é invocada no módulos *feeds.feeds*, e tem como parâmetro o ficheiro *feeds.txt* que contém as notícias extraídas a partir do feedparser. O objectivo desta função é indexar cada notícia, para depois se efectuarem

pesquisas e ser retornado o id das notícias correspondentes à pesquisa, assim como a frequência a que ela ocorre.

#### 2.3 Armazenamento

É importante sublinhar, que a extração do conteúdo dos artigos das notícias é feita para o ficheiro *feeds.txt* e da mesma forma, os títulos das notícias para o ficheiro *title\_file.txt*.

No ficheiro *feeds.txt*, são armazenados os conteúdos de cada artigo e para cada um deste é criado e adicionado no início um id. No ficheiro *title\_file.txt*, são armazenados os títulos da cada notícia com o respectivo equivalente id. Este id é colocado no início de cada artigo e no início de cada respectivo título por fim a se poderem processar algumas operações e associar cada notícia com o seu respectivo título.

Este armazenamento é feito no módulo feeds, dentro da função feeds. Esta módulo contém mecanismos para evitar o armazenamento de artigos duplicados que serão descritos na subsecção 2.4 deste relatório.

#### 2.4 Tratamento de notícias Duplicadas

Como é comum acontecer, algumas vezes notícias repetem-se. Apesar de não existir maneira 100% precisa de evitar estes casos, este projecto inclui métodos para evitar armazenar a mesma notícia repetidamente.

Aquando da extração das notícias e dos respectivos títulos, no módulo *feeds.py* é criado um hash SHA-1 do título da notícia e armazenado no ficheiro *hash\_file.txt*. A cada extração, após ler-se o título, é criado um hash deste e lê-se o ficheiro *hash\_file.txt* para se verificar se o hash já existe. Se não existir, então a notícia ainda não foi extraída e pode-se proceder a extração descrita anteriormente. De forma inversa, se a hash existir no ficheiro *hash\_file.txt*, significa que a notícia já foi anteriormente extraída e é ignorado o processo de extração.

O algoritmos de criptografia escolhido foi o SHA-1 devido a sua robusteza. O SHA-1 produz digests de 160bits levando a uma muito baixa probabilidade de repetição. No entanto o mesmo conteúdo de fonte irá criar sempre o mesmo digest, i. e., um título repetido irá gerar sempre o mesmo digest, bastando uma ligeira mudança (ex.: um acento ou uma letra), para daí ser gerado um digest completamente diferente.

### 3. RANKING

Nesta secção, será explicado como foi feito o ranking das personalidades em cada notícia assim como as ferramentas para geração de gráficos representantes destes valores.

### 4. MÉTODO DE RANKING

Uma vez extraídas as notícias e devidamente armazenadas, estas são indexadas usando a ferramenta Whoosh. Para tal, as notícias armazenadas no ficheiro *feeds.txt* são percorridas e partidas em palavras, e para cada notícia é associado um id gerado pela função de indexação. É de notar que as notícias no ficheiro *feeds.txt* se encontram no estado bruto com ainda alguma tags HTML. Apesar destas não influenciarem qualquer tipo de resultado, as notícias são devidamente "limpas" antes de serem indexadas e assim seguem de forma esperada. Os ficheiros do index são armazenados na subdirectoria *indexdir\_proj*.

Uma vez indexadas as notícias, é invocado no script inicial o módulo *search.py* que usa também a ferramenta Whoosh. Esta ferramenta percorre os ficheiros de index e retira todos os valores de score em BM25.

Neste projecto também são criados gráficos para fácil visualização de alguns dados. Para tal, são calculadas as médias dos rankings de cada entidade e as 20 entidades com valores mais relevantes são escritos para o ficheiro *plotBM25.dat* no subdirectório *plots* na forma **Valor Entidade**. Adicionalmente, é criado o ficheiro *plotBM25.gp* ainda no subdirectório *plots* que contém toda a informação necessária para a formatação e criação do gráfico de ranking.

A ferramenta para a criação de gráficos é explicada com mais precisão na secção 7.

### 5. ANÁLISE DAS ENTIDADES

Nesta secção, será detalhado o modo como é feita a extração das entidades políticas encontradas nos feeds de notícias.

#### 5.1 Método de Extração

No script inicial é invocado a função *personalidadesTratamento*, passando como parâmetro a *list\_personalities*, que se encontra no módulo *FIndEntities*. Esta função extrai os políticos do ficheiro *personalities.txt* e passa os nomes dos políticos representados nesse ficheiro, para a *list\_personalities*. A outra função do módulo *FIndEntities*, é invocada a partir dos módulos *sentiments.sentiments*, antes do tratamento da notícia. Nessa função, *\_SearchEntities*, passa-se como parâmetros a notícia e a *list\_personalities*. O objectivo desta função é extrair os nomes dos políticos encontrados na notícia. De uma forma mais detalhada, pode-se dizer que com o auxílio do nltk conseguiu-se extrair as entidades da seguinte forma:

- Para cada frase da notícia (*sent\_tokenize(news)*) e para cada marcação de entidade da palavra (*ne\_chunk(nltk.pos\_tag(nltk.word\_tokenize(sentence)))*)
- É verificado se a marca é um node. Se for este verifica se a entidade é uma "PERSON", e em caso positivo este começa a construir o nome da pessoa buscando os valores nas folhas

- Após a junção este verifica se o nome se encontra na *list\_personalities* e adiciona-o a uma lista

Esta função retorna a lista de personalidades encontradas de cada notícia.

### 6. ANÁLISE DE SENTIMENTOS

Nesta secção será abordada a forma de extração do sentimento captado na notícia.

#### 6.1 Método de Análise

Este método foi dividido em duas partes: **Tratamento dos Sentimentos (Subsecção 6.1.1)** e **Sentimentos da notícia (Subsecção 6.1.2)**

##### 6.1.1 Tratamento dos Sentimentos

Numa primeira fase, ao correr o script inicial, *scriptInicial.py*, é invocada a função *sentilexTratamento*, passando como parâmetros *lexiDic*, *tuple*. Após a invocação da função, este lê o ficheiro *sentilex* e retém as informações mais importantes do ficheiro tais como a *root*, que é a palavra que pode aparecer no texto, e a polaridade da *root*. Após a extração da informação importante do ficheiro, este passa a primeira palavra da *root* como *key* do dicionário *lexiDic*, e na *tuple* coloca o resto da expressão, o comprimento da expressão e a polaridade. O motivo pelo qual se criou este dicionário foi para facilitar a pesquisa dos sentimentos e das expressões que se pode encontrar na notícia, facilitando assim a comparação entre palavras.

##### 6.1.2 Sentimento da notícia

Após o tratamento dos sentimentos, já se está apto para analisar se a notícia tem uma conotação positiva ou negativa em relação ao tema que se está a analisar, a política. A função *sentimentos*, tem como parâmetros *lexiDic* e *opinionDic*. A função extrai os sentimentos da notícia fazendo com que se consiga fazer um cálculo relativo à polaridade sentimental, determinando assim se a notícia é sentimentalmente positiva ou negativa. Esta função foi realizada com auxílio da ferramenta *nltk*, para a separar a notícia em palavras. A comparação foi feita a partir do dicionário que continha os sentimentos já tratados com cada palavra da notícia. Quando se encontra uma correspondência, é verificado se aquela palavra tem continuação, i.e, se faz parte de uma expressão. Caso não tenha quer dizer que a palavra é única e é somada à polaridade da notícia a polaridade da palavra. Se a palavra for negativa, é subtraído um valor ao total da polaridade da notícia, se for positiva é somado um valor e em caso neutro o valor de polaridade total não é alterado. Caso o dicionário verifica que a lista contém uma expressão, então é comparado a próxima palavra com a próxima palavra da expressão, e assim sucessivamente. Este ciclo só termina se caso encontrar correspondência ou se percorrer todos os elementos da lista e não encontrando nenhuma correspondência. Caso este encontre correspondência, então verifica a polaridade da expressão, subtraindo-se à polaridade da notícia um valor se for negativa, somando se for positivo e mantendo o valor em caso de ser neutra. Após a análise este passa ao dicionário *opinionDic*, o id com o respectivo título da notícia como *key* e passa como *value*, uma tupla com uma lista de políticos encontrados na notícia *politiciansList* e o peso do sentimento da notícia.

## 7. FERRAMENTA DE PLOTTING

A fim de apresentar alguns valores relevantes recolhidos durante o projecto, foi usada a ferramenta *Gnuplot*.

O Gnuplot é altamente flexível e permite criar variados tipos de gráficos. Este programa só necessita de um ficheiro de entrada (no caso deste projecto do tipo *.dat*) que recebe os valores a serem tratados e outro ficheiro do tipo *.gp* com as definições necessárias para o tratamento do ficheiro *.dat* e para a apresentação e criação do gráfico.

Devido a algumas limitações na apresentação final dos valores de ranking, o número de valores apresentados teve de ser reduzido ao top 20 por forma a ser possível a leitura dos resultados. Isto foi devido à existência de mais de 1500 valores aquando dos testes efectuados, tornando-se impossível perceberem-se tantos pontos num gráfico. Adicionalmente, a quantidade de valores de ranking obtidos são sempre muito elevados e podem aumentar ainda a valores bem superior aos obtidos nos testes.

Os gráficos obtidos durante os testes pode ser visto no Apêndice, nas figuras 3 e 4.

## 8. RESULTADOS OBTIDOS

Nesta seção serão apresentados os resultados obtidos relativos a:

- Sentimento da notícia (secção 8.1),
- Score de cada notícia (secção 8.2).

### 8.1 Sentimentos das Notícias

Os resultados obtidos para na análise de sentimentos relativo à entidade são devolvidos na forma: *id notícia - título notícia, políticos, resultado final da soma da análise de sentimentos*.

Ex.:

*1 - Passos promete para breve guião da reforma do Estado*

*políticos:*

*Paulo Portas*

*Passos Coelho*

*Valor da notícia: 4*

Os resultados obtidos nos testes encontram-se demonstrados em anexo na figura 2

### 8.2 Score de cada Entidade

Os resultados obtidos no scoring BM25 são devolvido na forma de percentagem sendo apresentados os valores para cada notícia e um valor médio geral.

Ex.:

*Vítor Gaspar*

*Score Doc: 5 ==> 4.77950871124*

*Score Doc: 3 ==> 4.04907450246*

*Average rank: 4.41429160685*

Este output imprime o nome da personalidade seguido de cada notícia com o seu respectivo id e score. Finalmente, para cada político, no final de serem levantados todos os scores, é calculado e apresentado o valor médio total.

Os resultados obtidos nos testes encontram-se demonstrados em anexo na figura 1

## 9. CONCLUSÕES

Na realização deste projecto, foi interessante perceber como alguma técnicas de recolha de informação e análise das mesmas é efectuado. Existe uma variada quantidade de ferramentas e o estudo e escolha das que pareceram mais adequadas demonstrou-se recompensador e interessante.

É de notar que para o cálculo de ranking, a recolha de personalidades vem de um ficheiro já pré-definido. Assim, este calculo não é feito de forma "inteligente" em que são estudadas variações dos nomes das entidades (ex.: Pedro Passos Coelho = Passos Coelho) não reflectindo assim a precisão esperada. Este ponto poderá ser melhorado no futuro aumentando a precisão desta ferramenta.

Também é importante referir que a ferramenta foi pensada e criada em específico para os feeds de notícias de ordem política do Diário de Notícias e Jornal de Notícias, não garantindo assim o funcionamento com outros feeds.

Finalmente, a precisão geral da ferramenta poderia ser globalmente melhorada usando técnicas mais avançadas para o reconhecimento das variações de nomes das personalidades e com o uso de técnicas mais avançadas de ranking e análise de sentimentos. Estes poderão ser pontos a pegar e desenvolver com mais profundidade no futuro.

## APPENDIX

### A. RESULTADOS DE TESTES

